



BAGNO INTELLIGENTE

DAL DATO ALLA
SCELTA

Strumenti Statistici per l'Analisi di Dati Aziendali, A.A 2025-2026

Andrea Cocco Gianmarco Rosa Giorgia Morello



AZIENDA





AZIENDA

- PMI LOCALE VENETA
- ESPORTATRICE PER OLTRE IL 20%
- SHOWROOM IN EUROPA
- PARTECIPAZIONE A FIERE IN EUROPA



DATI FORNITI DALL'AZIENDA



Dataset 1

16 serie storiche mensili relative a mobili da bagno, distinte in base alla combinazione di colore (antracite, bianco, grigio e noce) e dimensione (60 cm, 80 cm, 100 cm e 120 cm).



DATI FORNITI DALL'AZIENDA



Dataset 1

16 serie storiche mensili relative a mobili da bagno, distinte in base alla combinazione di colore (antracite, bianco, grigio e noce) e dimensione (60 cm, 80 cm, 100 cm e 120 cm).



Dataset 2

Indagine sulle preferenze di acquisto degli agenti, in cui vengono mostrate diverse configurazioni di prodotto.

Il dataset è composto da 150 osservazioni e 11 variabili (colore, dimensione, tipo di installazione, numero di cassette,..).



OBIETTIVI



Obiettivo 1

- Analisi delle serie storiche
- Clustering delle serie storiche
- Identificazione di eventuali pattern
- Miglior modello previsivo



OBIETTIVI



Obiettivo 1

- Analisi delle serie storiche
- Clustering delle serie storiche
- Identificazione di eventuali pattern
- Miglior modello previsivo



Obiettivo 2

- Analisi esplorativa
- Analisi delle preferenze
- Market basket analysis
- APP



OBIETTIVI



Obiettivo 1

- Analisi delle serie storiche
- Clustering delle serie storiche
- Identificazione di eventuali pattern
- Miglior modello previsivo




Obiettivo 2

- Analisi esplorativa
- Analisi delle preferenze
- Market basket analysis
- APP


Al fine di rispondere ai quesiti di business posti dall'azienda, sono stati utilizzati sia i metodi presentati durante il corso sia metodologie acquisite in corsi precedenti. Si riportano nella presentazione i risultati di maggior interesse.




PUNTO DI PARTENZA




PUNTO DI PARTENZA



PUNTO DI PARTENZA



PUNTO DI PARTENZA



LA CAMPAGNA PUBBLICITARIA


La campagna pubblicitaria analizzata riguarda la **promozione di alcuni prodotti specifici**, identificabili nelle categorie **antracite 60, antracite 80, grigio 60 e grigio 80**.

Secondo quanto riportato, le attività promozionali si collocano indicativamente nell'intervallo **febbraio 2015 – luglio 2015**.

L'evento è associato alla partecipazione dell'impresa a una fiera di settore, ritenuta il principale driver degli shock osservati.



LA CAMPAGNA PUBBLICITARIA




La campagna pubblicitaria analizzata riguarda la **promozione di alcuni prodotti specifici**, identificabili nelle categorie **antracite 60, antracite 80, grigio 60 e grigio 80**.

Secondo quanto riportato, le attività promozionali si collocano indicativamente nell'intervallo **febbraio 2015 – luglio 2015**.


L'evento è associato alla partecipazione dell'impresa a una fiera di settore, ritenuta il principale driver degli shock osservati.



PRIMI RISULTATI OTTENUTI




PRIMI RISULTATI OTTENUTI




Stima del modello di
Bass su tutti i dati



CLUSTERING FUNZIONALE SU SCORES F-PCA




CLUSTERING FUNZIONALE SU SCORES F-PCA



Si è applicato clustering agli scores funzionali per individuare gruppi di serie caratterizzate da dinamiche temporali simili.



CLUSTERING FUNZIONALE SUI COEFFICIENTI DELLE FUNZIONI DI BASE





CEO Wardiere Inc.

“Vorrei essere in grado di capire la quantità da mandare in produzione oggi, per ottimizzare la produzione e le risorse”



IDEA



Utilizzare la previsione a 2 passi in avanti, tramite approccio expanding windows.
Vengono testati diversi modelli, analizzandone le caratteristiche distintive e le rispettive prestazioni.



CEO Wardiere Inc.

“Vorrei essere in grado di capire la quantità da mandare in produzione oggi, per ottimizzare la produzione e le risorse”



MODELLI **PROVATI**

No	Modello	MSE
----	---------	-----

01	Modello di Bass	8.29
----	-----------------	------

02	Rolling mean	7.23
----	--------------	------

03	Modello lineare	5.85
----	-----------------	------

04	XGBoost	3.57
----	---------	------

05	Prophet	2.90
----	---------	------



VALUTAZIONE D'ACQUISTO DEGLI AGENTI


Con lo studio del secondo dataset l'obiettivo è valutare la propensione degli agenti all'acquisto dei prodotti mostrati.

Informazioni sul dataset

Si compone di 150 osservazioni e 11 variabili relative alle caratteristiche dei mobili da bagno proposti agli agenti e alla relativa propensione all'acquisto. In particolare, le variabili considerate riguardano:

- il giorno e l'orario di presentazione della proposta (non inclusa nelle analisi successive);
- il colore del mobile;
- la dimensione del mobile bagno;
- la tipologia di lavabo;
- la presenza di configurazione all inclusive;
- il numero di cassetti;
- la presenza di ante;
- la forma della specchiera;
- la tipologia del mobile (a terra o sospeso);
- il tipo di illuminazione;
- la risposta dell'agente rispetto all'acquisto del prodotto.


Tutte le altre variabili sono state trattate come variabili categoriali



SCOPI DELL'ANALISI

Analisi esplorativa

Di seguito viene presentata una prima analisi esplorativa delle variabili considerate maggiormente rilevanti ai fini della valutazione dell'acquisto da parte del cliente, attraverso la rappresentazione dei relativi istogrammi di frequenza.



SCOPI DELL'ANALISI

Analisi esplorativa

Di seguito viene presentata una prima analisi esplorativa delle variabili considerate maggiormente rilevanti ai fini della valutazione dell'acquisto da parte del cliente, attraverso la rappresentazione dei relativi istogrammi di frequenza.



Stima di modelli inferenziali e Machine Learning

Di seguito si stimano una serie di modelli, a partire da quelli più interpretativi ai "Black-Box", al fine di trovare i migliori in termini di trade-off tra **performance** e **interpretazione**.



SCOPI DELL'ANALISI

Analisi esplorativa

Di seguito viene presentata una prima analisi esplorativa delle variabili considerate maggiormente rilevanti ai fini della valutazione dell'acquisto da parte del cliente, attraverso la rappresentazione dei relativi istogrammi di frequenza.



Stima di modelli inferenziali e Machine Learning

Di seguito si stimano una serie di modelli, a partire da quelli più interpretativi ai "Black-Box", al fine di trovare i migliori in termini di trade-off tra **performance** e **interpretazione**.

Evaluation Model


Si riportano infine le performance dei modelli sulla base di quattro metriche specifiche — CE, FP, FN e F1 — al fine di confrontarne i risultati e individuare i modelli migliori per ciascuna metrica. Ove possibile, vengono inoltre fornite interpretazioni dei risultati ottenuti.



Analisi esplorative principali

Si riportano di seguito alcune analisi esplorative relative alle principali variabili potenzialmente rilevanti per lo studio delle preferenze degli agenti, tra cui:



- la variabile di risposta (acquisto sì/no),
- il tipo di prodotto (sospeso o a terra),
- la dimensione mobile (60, 80, 100, 120 cm),
- il numero di cassette (da 0 a 4).



Analisi esplorative principali

Si riportano di seguito alcune analisi esplorative relative alle principali variabili potenzialmente rilevanti per lo studio delle preferenze degli agenti, tra cui:




- la variabile di risposta (acquisto sì/no),
- il tipo di prodotto (sospeso o a terra),
- la dimensione mobile (60, 80, 100, 120 cm),
- il numero di cassette (da 0 a 4).



Analisi esplorative principali

Si riportano di seguito alcune analisi esplorative relative alle principali variabili potenzialmente rilevanti per lo studio delle preferenze degli agenti, tra cui:





- la variabile di risposta (acquisto sì/no),
- il tipo di prodotto (sospeso o a terra),
- la dimensione mobile (60, 80, 100, 120 cm),
- il numero di cassette (da 0 a 4).



Analisi esplorative principali

Si riportano di seguito alcune analisi esplorative relative alle principali variabili potenzialmente rilevanti per lo studio delle preferenze degli agenti, tra cui:


- la variabile di risposta (acquisto sì/no),
- il tipo di prodotto (sospeso o a terra),
- la dimensione mobile (60, 80, 100, 120 cm),
- il numero di cassette (da 0 a 4).



DAL CLUSTERING GERARCHICO...

In una prima fase si applica un **clustering gerarchico** con **distanza di Gower**:

Si procede con un'analisi descrittiva di alcune distribuzioni condizionate delle principali variabili categoriali all'interno di ciascun cluster:



`hclust (*, "complete")`




DAL CLUSTERING GERARCHICO...

In una prima fase si applica un **clustering gerarchico** con **distanza di Gower**:

Si procede con un'analisi descrittiva di alcune distribuzioni condizionate delle principali variabili categoriali all'interno di ciascun cluster:

Cluster	Tipo dominante	Dimensione dominante	Cassetti dominanti
1	sospeso	60-80 cm	2-3
2	sospeso	60-100 cm	1-2
3	a terra	100-120 cm	2



hclust (*, "complete")


Come noto, i metodi gerarchici hanno però dei limiti...



...ALLO STUDIO DELLE K-MEDIE

Successivamente, i risultati vengono confrontati con un approccio k-means per la determinazione del numero ottimale di gruppi.

Si procede con un'analisi descrittiva di alcune distribuzioni condizionate delle principali variabili categoriali all'interno di ciascun cluster:




...ALLO STUDIO DELLE K-MEDIE

Successivamente, i risultati vengono confrontati con un approccio k-means per la determinazione del numero ottimale di gruppi.

Si procede con un'analisi descrittiva di alcune distribuzioni condizionate delle principali variabili categoriali all'interno di ciascun cluster:

Cluster	Tipo dominante	Dimensione dominante	Cassetti dominanti
1	sospeso	60 cm	2
2	sospeso	80 cm	3
3	a terra	100-120 cm	1-3




MARKET BASKET ANALYSIS

Sono state estratte regole di associazione tramite l'algoritmo Apriori.

Sono stati utilizzati i parametri di **supporto ($\geq 10\%$)** e **confidence ($\geq 70\%$)** per selezionare le regole più frequenti e affidabili.

Le regole sono state poi ordinate in base al lift per evidenziare le associazioni più informative.




MARKET BASKET ANALYSIS

Sono state estratte regole di associazione tramite l'algoritmo Apriori.

Sono stati utilizzati i parametri di **supporto ($\geq 10\%$)** e **confidence ($\geq 70\%$)** per selezionare le regole più frequenti e affidabili.

Le regole sono state poi ordinate in base al lift per evidenziare le associazioni più informative.

Di seguito si riportano alcune regole di associazione ridondanti individuate tra i diversi gruppi **antecedente-consequente**.




MARKET BASKET ANALYSIS

Sono state estratte regole di associazione tramite l’algoritmo Apriori.
Sono stati utilizzati i parametri di **supporto (≥ 10%)** e **confidence (≥ 70%)** per selezionare le regole più frequenti e affidabili.
Le regole sono state poi ordinate in base al lift per evidenziare le associazioni più informative.

Di seguito si riportano alcune regole di associazione ridondanti individuate tra i diversi gruppi **antecedente–conseguente**.

Antecedente	Conseguente	Lift
60 cm, rettangolare, sospeso	senza illuminazione	2.945
due cassette, no illuminazione, sospeso	60 cm	2.275
100 cm, rettangolare	a terra	1.928
80 cm, tre cassette	barra led	1.875



PRESENTAZIONE **RISULTATI**

ALCUNI RISULTATI INFERENZIALI

- Le prestazioni dei modelli sono state valutate tramite alcune metriche di classificazione ottenute dalla matrice di confusione: classificazione errata (CE), falsi positivi (FP), falsi negativi (FN) e indice F1.
- Si presentano di seguito alcuni risultati inferenziali ottenuti tramite un modello lineare generalizzato (GLM) per risposta binaria, finalizzato a studiare la propensione all'acquisto degli agenti. In particolare, viene riportato l'output del modello selezionato mediante procedura stepwise forward.

Variabile

z-value

p-value



PRESENTAZIONE **RISULTATI**

ALCUNI RISULTATI INFERENZIALI



- Le prestazioni dei modelli sono state valutate tramite alcune metriche di classificazione ottenute dalla matrice di confusione: classificazione errata (CE), falsi positivi (FP), falsi negativi (FN) e indice F1.
- Si presentano di seguito alcuni risultati inferenziali ottenuti tramite un modello lineare generalizzato (GLM) per risposta binaria, finalizzato a studiare la propensione all'acquisto degli agenti. In particolare, viene riportato l'output del modello selezionato mediante procedura stepwise forward.

Variabile	Coefficiente	z-value	p-value
illuminazione: senza illuminazione	-3.217	-3.579	<0.001
lavabo: sovrapposto	-1.498	-2.383	0.017
all inclusive: yes	1.625	2.601	0.009
dimensione: 100 cm	-2.189	-2.275	0.023



RISULTATI DAL LASSO LOGISTICO

Si riportano di seguito le variabili selezionate dal lasso logistico, una volta effettuata l'ottimizzazione dell'iperparametro lambda tramite la regola 1 errore standard.



RISULTATI DAL LASSO LOGISTICO

Si riportano di seguito le variabili selezionate dal lasso logistico, una volta effettuata l'ottimizzazione dell'iperparametro lambda tramite la regola 1 errore standard.

Variabile	Coefficiente	Effetto
all_inclusive = yes	0.0002	+
numero_cassetti = 2	0.326	+
type = sospeso	0.303	+
illuminazione=senza	-0.995	-





GRAFICO IMPORTANZA RANDOM FOREST

Al fine di verificare la coerenza dei risultati ottenuti con i modelli precedentemente stimati, si riporta di seguito il grafico di importanza delle variabili della Random Forest.


- **Numero di alberi** è stato fissato a **500**;
- Iperparametro che indica il numero di variabili campionate (**mtry**) è stato selezionato mediante ricerca su griglia e valutazione dell'errore sul set di validazione (risultato essere pari a **3**).



GRAFICO IMPORTANZA RANDOM FOREST

Al fine di verificare la coerenza dei risultati ottenuti con i modelli precedentemente stimati, si riporta di seguito il grafico di importanza delle variabili della Random Forest.


- **Numero di alberi** è stato fissato a **500**;
- Iperparametro che indica il numero di variabili campionate (**mtry**) è stato selezionato mediante ricerca su griglia e valutazione dell'errore sul set di validazione (risultato essere pari a **3**).



FOCUS IMPLEMENTAZIONE XGBOOST

Si è prestata particolare attenzione all'implementazione del modello XGBoost, applicando diverse configurazioni al fine di confrontarne le prestazioni. In particolare, sono stati stimati i seguenti modelli:

- XGBoost senza tuning learning rate con boosting ad albero singolo (stumps);
- XGBoost senza tuning learning rate con profondità massima pari a 4;
- XGBoost con learning rate pari a 0.01 e boosting ad albero singolo (stumps);
- XGBoost con learning rate pari a 0.01 e profondità massima pari a 4.




FOCUS IMPLEMENTAZIONE XGBOOST

Si è prestata particolare attenzione all'implementazione del modello XGBoost, applicando diverse configurazioni al fine di confrontarne le prestazioni. In particolare, sono stati stimati i seguenti modelli:

- XGBoost senza tuning learning rate con boosting ad albero singolo (stumps);
- XGBoost senza tuning learning rate con profondità massima pari a 4;
- XGBoost con learning rate pari a 0.01 e boosting ad albero singolo (stumps);
- XGBoost con learning rate pari a 0.01 e profondità massima pari a 4.


Si riportano alcuni primi risultati:

Modello	Depth	Shrinkage	Alberi ottimali	Test error minimo
XGBoost stumps	1	NA	3632	0.155
XGBoost depth=4	4	NA	30	0.155
XGBoost stumps shrinkage	1	0.01	97	0.177
XGBoost depth=4 shrinkage	4	0.01	113	0.177





I modelli con interaction depth pari a 1 e 4 hanno mostrato un errore minimo comparabile sul test set. Tuttavia, il modello con **profondità pari a 4** è stato preferito in quanto raggiunge la performance ottimale con un numero significativamente inferiore di alberi (pari a 30), risultando quindi più efficiente dal punto di vista computazionale.

Su tale modello stimato si è ritenuto interessante analizzare i **Partial Dependence Plots** di alcune variabili, selezionate sulla base della loro Relative Importance. Si è potuto così interpretarne anche la probabilità della risposta predetta al variare delle singole variabili, mediando rispetto alle altre covariate.






I modelli con interaction depth pari a 1 e 4 hanno mostrato un errore minimo comparabile sul test set. Tuttavia, il modello con **profondità pari a 4** è stato preferito in quanto raggiunge la performance ottimale con un numero significativamente inferiore di alberi (pari a 30), risultando quindi più efficiente dal punto di vista computazionale.

Su tale modello stimato si è ritenuto interessante analizzare i **Partial Dependence Plots** di alcune variabili, selezionate sulla base della loro Relative Importance. Si è potuto così interpretarne anche la probabilità della risposta predetta al variare delle singole variabili, mediando rispetto alle altre covariate.



I modelli con interaction depth pari a 1 e 4 hanno mostrato un errore minimo comparabile sul test set. Tuttavia, il modello con **profondità pari a 4** è stato preferito in quanto raggiunge la performance ottimale con un numero significativamente inferiore di alberi (pari a 30), risultando quindi più efficiente dal punto di vista computazionale.

Su tale modello stimato si è ritenuto interessante analizzare i **Partial Dependence Plots** di alcune variabili, selezionate sulla base della loro Relative Importance. Si è potuto così interpretarne anche la probabilità della risposta predetta al variare delle singole variabili, mediando rispetto alle altre covariate.



VALUTAZIONE DELLE PERFORMANCE PREDITTIVE

Di seguito si riportano le metriche di valutazione dei metodi adottati, ovvero errore di classificazione, falsi positivi, falsi negativi e indice F1



VALUTAZIONE DELLE PERFORMANCE PREDITTIVE

Di seguito si riportano le metriche di valutazione dei metodi adottati, ovvero errore di classificazione, falsi positivi, falsi negativi e indice F1

Modello	CE	FP	FN	F1
GLM selezione stepwise	0.288	0.533	0.166	0.793
Lasso logistico	0.222	0.266	0.200	0.827
Albero classificazione	0.400	0.533	0.333	0.689
MARS con interazioni	0.177	0.466	0.033	0.878
RF con mtry ottimizzato	0.244	0.533	0.100	0.831
PPR	0.266	0.466	0.166	0.806



Modello	CE	FP	FN	F1
Bagging (500 alberi)	0.222	0.466	0.100	0.843
LDA	0.200	0.400	0.100	0.857
XGBoost stump	0.155	0.333	0.066	0.888
XGBoost depth 4	0.155	0.333	0.066	0.888
XGBoost stump+learn	0.177	0.466	0.033	0.878
XGBoost depth 4+learn	0.177	0.466	0.033	0.878




Modello	CE	FP	FN	F1
Bagging (500 alberi)	0.222	0.466	0.100	0.843
LDA	0.200	0.400	0.100	0.857
XGBoost stump	0.155	0.333	0.066	0.888
XGBoost depth 4	0.155	0.333	0.066	0.888
XGBoost stump+learn	0.177	0.466	0.033	0.878
XGBoost depth 4+learn	0.177	0.466	0.033	0.878

NOTA: Si è deciso di evidenziare le metriche migliori




Top 5 performance in termini di CE



Conclusioni interessanti ?



Top 5 performance in termini di CE




Conclusioni interessanti?

Si osserva che le migliori performance in termini di CE sono ottenute dalle quattro varianti del modello XGBoost, mentre il quinto miglior risultato è associato al modello MARS con interazioni. Si riportano di seguito i valori della metrica per ciascun modello.




CONSIDERAZIONI FINALI




**PUNTI DI
FORZA**



CONSIDERAZIONI FINALI



CONSIDERAZIONI FINALI



COME TRASFORMARE LE PREFERENZE... IN DECISIONI GUIDATE?

L'idea nasce dalla possibilità di **utilizzare i dati di preferenza** dei clienti per costruire un sistema in grado di **ordinare** e **guidare** le scelte di configurazione in modo intelligente.




COME TRASFORMARE LE PREFERENZE... IN DECISIONI GUIDATE?

L'idea nasce dalla possibilità di **utilizzare i dati di preferenza** dei clienti per costruire un sistema in grado di **ordinare** e **guidare** le scelte di configurazione in modo intelligente.

IDEA!

Un'app interattiva che trasforma le preferenze del cliente in un percorso di scelta guidato dall'intelligenza artificiale.

A faint, stylized lightbulb icon is visible in the background of the orange box, symbolizing an idea or insight.

COME TRASFORMARE LE PREFERENZE... IN DECISIONI GUIDATE?

L'idea nasce dalla possibilità di **utilizzare i dati di preferenza** dei clienti per costruire un sistema in grado di **ordinare** e **guidare** le scelte di configurazione in modo intelligente.

Sviluppo **APP**:

1. DATI CLIENTI



IDEA!

Un'app interattiva che trasforma le preferenze del cliente in un percorso di scelta guidato dall'intelligenza artificiale.



COME TRASFORMARE LE PREFERENZE... IN DECISIONI GUIDATE?

L'idea nasce dalla possibilità di **utilizzare i dati di preferenza** dei clienti per costruire un sistema in grado di **ordinare** e **guidare** le scelte di configurazione in modo intelligente.

Sviluppo **APP**:

1. DATI CLIENTI



2. IMPLEMENTAZIONE
MODELLO XGBOOST



IDEA!

Un'app interattiva che trasforma le preferenze del cliente in un percorso di scelta guidato dall'intelligenza artificiale.



COME TRASFORMARE LE PREFERENZE... IN DECISIONI GUIDATE?

L'idea nasce dalla possibilità di **utilizzare i dati di preferenza** dei clienti per costruire un sistema in grado di **ordinare** e **guidare** le scelte di configurazione in modo intelligente.

Sviluppo APP:


1. DATI CLIENTI



2. IMPLEMENTAZIONE
MODELLO XGBOOST



3. CONFIGURATORE
BAGNO GUIDATO



IDEA!

Un'app interattiva che trasforma le preferenze del cliente in un percorso di scelta guidato dall'intelligenza artificiale.





Wardiere Inc.

Design, funzionalità e comfort!

Grazie per l'attenzione.

Further questions?

